



UNIVERSIDAD DE CÓRDOBA



UNIVERSIDAD DE CÓRDOBA
INSTITUTO DE ESTUDIOS DE POSTGRADO

Máster Universitario en Inteligencia
Computacional e Internet de las Cosas

**Análisis y desarrollo de sistemas RAG sobre
SLM locales para la optimización del acceso a
información de espacios naturales de la Junta
de Andalucía**

AUTOR

Anastasia Kuzmina

DIRECTORES

José Raúl Romero Salguero

Isabel Durán Muñoz

1. Introducción y Antecedentes

En los últimos años, los asistentes conversacionales (*chatbots*) basados en inteligencia artificial han experimentado un crecimiento notable en numerosos sectores, cambiando la forma en que usuarios e instituciones acceden a la información (Gao et al., 2024).

Sin embargo, cuando estos sistemas se aplican en un sector específico, surge una de sus principales limitaciones: las «alucinaciones», es decir, la generación de respuestas creíbles pero falsas. Dependiendo del sector, las «alucinaciones» pueden afectar la fiabilidad del sistema y reducir su utilidad práctica. La arquitectura RAG (*Retrieval-Augmented Generation*) surge como una solución a este problema, combinando la recuperación semántica de información con la generación de lenguaje natural, permitiendo que las respuestas se apoyen en fuentes documentales concretas y reduciendo así la probabilidad de errores o invenciones (Lewis et al., 2021).

Además, el uso de LLM de ejecución local garantiza la seguridad de los datos y elimina dependencias externas, lo cual es crítico en el ámbito de la administración pública (Touvron et al., 2023).

1.1. Contexto Institucional: Proyecto NATURCOR-IA

Este Trabajo Fin de Máster se encuadra en el proyecto NATURCOR-IA (referencia 2025/UCO008/032599), que forma parte del XI Plan Propio Galileo de la UCO (2025), en concreto de la Modalidad IA (Proyectos UCO-Transfiere). NATURCOR-IA es un proyecto de investigación y transferencia que busca mejorar la accesibilidad al patrimonio natural de la provincia de Córdoba aplicando tecnologías avanzadas de inteligencia artificial y procesamiento del lenguaje natural.

Como resultado principal del proyecto, se desarrollará una plataforma web de carácter interactivo con un asistente virtual multilingüe, basado en tecnologías de inteligencia artificial generativa, con el fin de facilitar el acceso a la información sobre itinerarios de senderismo y espacios naturales protegidos.

Para dar respuesta a esta necesidad, el presente Trabajo Fin de Máster propone el diseño, implementación y evaluación de un sistema conversacional basado en RAG con SLM (*Small Language Models*) de ejecución local, orientado a optimizar el acceso a la información

de la plataforma de turismo natural de la Junta de Andalucía, analizando el impacto de los distintos parámetros de configuración sobre la calidad y fiabilidad de las respuestas generadas.

2. Objetivos

El objetivo de este TFM es desarrollar y evaluar un sistema de asistencia conversacional basado en la arquitectura RAG (*Retrieval-Augmented Generation*) y modelos de lenguaje pequeño de ejecución local (*Small Language Models*), con el fin de optimizar el acceso a la información de la plataforma de turismo natural de la Junta de Andalucía:

- Realizar un estudio previo sobre la aplicación de tecnologías de IA generativa y bases de datos vectoriales a la recuperación de información no estructurada.
- Analizar y comparar la idoneidad de las arquitecturas RAG para identificar la configuración más adecuada según los objetivos del sistema.
- Diseñar un pipeline de procesamiento documental que cubra las etapas de extracción de contenido (PDFs y web), segmentación (*chunking*), generación de embeddings e indexación vectorial.
- Desplegar un entorno de pruebas local basado en diferentes SLMs y arquitecturas RAG, configurando los distintos parámetros del sistema para realizar el análisis comparativo.
- Evaluar el rendimiento y la calidad de las respuestas generadas ante diferentes escenarios de consulta, analizando la reducción de alucinaciones y la precisión de la información.
- Extraer conclusiones sobre las configuraciones óptimas para este proyecto y proponer líneas de trabajo futuro.

3. Planificación y alcance del TFM

Para dar cumplimiento a los objetivos planteados, el trabajo se estructura en las siguientes etapas:

Eta ­ pa	Horas	%	Feb	Mar	Abr	May	Jun
I. Revisi ­ on bibliogr ­ fica	60	17%	40h	20h			
II. Dise ­ no del sistema	60	17%		30h	30h		
III. Desarrol ­ lo e implemen ­ taci ­ on	110	31%			50h	60h	
IV. Prue ­ bas y vali ­ daci ­ on	80	23%				40h	40h
V. Conclu ­ siones y trabajo futuro	40	12%					40h
Total	350h	100%	40h	50h	80h	100h	80h

Tabla 1. Planificaci­on del TFM por horas y por mes.

I. REVISI­ON BIBLIOGR­FICA

An­alisis de la literatura cient­fica y t­cnica relativa a los sistemas de recuperaci­on aumentada de informaci­on (RAG), los modelos de lenguaje peque­no con ejecuci­on local (SLM), y las bases de datos vectoriales. Asimismo, se estudiar­an los fundamentos del procesamien­to de lenguaje natural aplicado a la b­sq­ueda sem­antica, las m­tricas y t­nicas existentes para la evaluaci­on de la calidad de respuestas generadas.

II. DISE­NO DEL SISTEMA

Especificaci­on del dise­no t­cnico del sistema RAG, que describe el flujo completo desde la ingesta documental hasta la generaci­on de respuestas, y definici­on de los par­metros de configuraci­on objeto de an­alisis: estrategias de *chunking*, modelos de *embeddings*, tama­nos de contexto, selecci­on de los SLMs locales.

III. DESARROLLO E IMPLEMENTACI­ON

A partir del diseño técnico, se construirá el sistema funcional integrando la extracción de fuentes (PDFs y *web*), vectorización, indexación y generación de respuestas. Además, se implementará la lógica conversacional para garantizar que todos los elementos necesarios para el funcionamiento del sistema se integren correctamente.

IV. PRUEBAS Y VALIDACIÓN

Se harán pruebas sobre distintas configuraciones, para evaluar el rendimiento y la calidad de las respuestas con métricas adecuadas con el fin de medir el impacto de cada parámetro (modelos, *chunking*, etc.) en la reducción de alucinaciones y la exactitud de los resultados.

V. CONCLUSIONES Y TRABAJO FUTURO

El TFM finalizará con un análisis crítico de los resultados obtenidos, identificando qué configuraciones resultan más adecuadas para el caso de uso planteado y señalando aquellos aspectos que pueden servir de punto de partida para investigaciones posteriores.

Referencias

- Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, M., & Wang, H. (2024). *Retrieval-Augmented Generation for Large Language Models: A Survey*. <http://arxiv.org/abs/2312.10997>
- Hui, Y., Lu, Y., & Zhang, H. (2024). *UDA: A Benchmark Suite for Retrieval Augmented Generation in Real-world Document Analysis*. <http://arxiv.org/abs/2406.15187>
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2021). *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. <http://arxiv.org/abs/2005.11401>
- Touvron, H., Lavril, T., Izacard, G., Martinet, X., Lachaux, M.-A., Lacroix, T., Rozière, B., Goyal, N., Hambro, E., Azhar, F., Rodriguez, A., Joulin, A., Grave, E., & Lample, G. (2023). *LLaMA: Open and Efficient Foundation Language Models*. <http://arxiv.org/abs/2302.13971>
- Wan, Y., Liu, Y., Ajith, A., Grazian, C., Hoex, B., Zhang, W., Kit, C., Xie, T., & Foster, I. (2024). *SciQAG: A Framework for Auto-Generated Science Question Answering Dataset with Fine-grained Evaluation*. <http://arxiv.org/abs/2405.09939>